

DeepSeek 2026

从 R1 冲击波到 V4 Preview：百万上下文、开放权重、低价 API 与国产芯片适配，正在重写中国 AI 基础设施的叙事。



SIX QUESTIONS FOR ONE MODEL COMPANY

这份 PPT 回答六个问题

01

官方主线

V4 Preview 已接棒，而非 R2。

02

能力边界

开放权重逼近前沿，但第三方评测更谨慎。

03

成本武器

Flash / Pro 形成高低搭配。

04

系统工程

MoE、压缩注意力、DeepEP/DeepGEMM。

05

国产芯片

华为 Ascend 适配成为产业信号。

06

风险约束

监管、蒸馏争议与地缘政治。

ONE SENTENCE

V4 不是 一次模型更新

IT IS AN INFRA SIGNAL.

DeepSeek 2026 的核心，不再是“R2 何时来”，而是 V4 系列把模型、API、开源权重、国产芯片和资本叙事打包成一个基础设施命题。

判断 DeepSeek 的新框架：看 V4 是否稳定、看长上下文是否便宜可用、看国产硬件是否规模化、看监管是否限制海外渗透。

PUBLIC RELEASE SEQUENCE

真正的时间线：V4 已经接棒

2025.01

R1

低成本推理模型冲击全球估值锚点。

2025.12

V3.2

作为 V4 前的公开模型线继续迭代。

2026.04

V4

Preview 上线，Pro / Flash 双版本发布。

KEY DATE

2026
04.24

TWO-SPEED PORTFOLIO

V4 被拆成两种速度

01 DEEPSEEK-V4-PRO

能力上限

1.6T 总参数、49B 激活参数，面向复杂推理、长链 agent、代码与科学任务。

- 1M token context
- FP4 + FP8 mixed precision
- 旗舰评测与复杂 workflow

02 DEEPSEEK-V4-FLASH

成本入口

284B 总参数、13B 激活参数，把百万上下文能力下放到高频业务流。

- 1M token context
- 低价、高吞吐、快速响应
- 兼容旧 chat / reasoner 路由

MOE MAKES SIZE NON-LINEAR

大模型，稀疏激活

总参数塑造能力上限；激活参数决定一次推理真正参与计算的规模。



LONG CONTEXT IS NOT JUST LENGTH

1M context
不是营销数字

长文档、代码库和 agent 轨迹可以进入同一个推理空间。

Compressed Sparse Attention 与 HCA 让上下文不只是“能塞进去”。

真正问题是缓存、检索、引用和分段校验能否跟上。

V4 VERSUS V3.2 IN LONG CONTEXT SETTING

效率工程才是主角



0.0028

Flash cache-hit input / 1M tokens

USD

0.14

Flash cache-miss input / 1M tokens

USD

0.28

Flash output / 1M tokens

USD

07.24

旧模型名完全退役

UTC

OPERATIONAL CHECKLIST

迁移窗口只剩三个月

01

Map

旧模型名改为 v4-flash / v4-pro

02

Toggle

显式控制 thinking 与 effort

03

Cache

固定上下文走缓存策略

04

Observe

记录成本、延迟、失败率

INDEPENDENT SIGNAL

第三方评测 更谨慎

CAISI 的结论不是“V4 不强”，而是：最强中国模型，仍约落后美国前沿模型 8 个月，但成本效率突出。

整体差距

8

MONTHS

中国模型

#1

CAISI SO FAR

成本优势

5/7

BENCHMARKS

数学强项

97%


OTIS-AIME

DeepSeek 的护城河在系统层

从 FlashMLA、DeepEP 到 DeepGEMM，开源基础设施让模型权重变成可服务系统。

MODEL	V4-Pro / V4-Flash 开放权重与低价 API 扩散开发者心智。
KERNEL	FlashMLA / DeepGEMM 低精度矩阵与推理 kernel 降低服务成本。
SYSTEM	DeepEP / 3FS / DualPipe MoE 通信、存储与并行训练构成工程壁垒。

SYSTEM



KERNEL

MODEL

国产算力闭环

从“能运行”到“能规模化”

V4 对华为 Ascend 的适配是产业信号。但真正的分水岭，是国产硬件在真实流量下能否跑出可维护、可扩展、可核算的总成本。



THREE FORCES ARRIVED AT ONCE

为什么 2026 是节点

01

成本锚点重置

DeepSeek 继续压低 token 单价，迫使闭源模型解释溢价。

10×

02

长上下文产品化

1M context 让代码库、长文档与 agent 轨迹进入同一工作区。

1M

03

国产栈协同

模型、kernel、通信库与 Ascend 适配开始形成同一条产业链。

V4

FUNDING REPORTS REMAIN MEDIA-SOURCED

资本给出的价格信号

估值传闻

\$45B

TechCrunch / Bloomberg / FT 转引，未见官方成交确认。

此前锚点

\$20B+

腾讯、阿里洽谈入股报道推高市场预期。

产业资本

国家基金

若成真，DeepSeek 将更深嵌入国产算力政策。

战略变量

独立性

外部股东可能改变开放权重与平台中立叙事。

站队风险

云生态

云厂商绑定会影响 API 分发与私有部署合作。

利润约束

商业化

低价 API 与高估值之间存在天然张力。

RISK STACK

越基础设施化，风险越前置

- 01

监管

政府设备限制、数据安全、关键基础设施采购审查。

- 02

蒸馏

Anthropic 指控带来声誉与法律不确定性。

- 03

地缘

芯片出口管制、海外企业采购与供应链审计。

- 04

开源

权重扩散增强生态，也放大滥用与监管压力。

THE PRESSURE IS ASYMMETRIC

DeepSeek 不必全面第一

只要在大量真实任务中足够强、足够便宜、足够开放，它就能持续压缩闭源前沿模型的价格解释空间。

OPEN 开放权重	CHEAP 低价 API	LONG 1M context	LOCAL 国产栈协同
--------------	-----------------	--------------------	----------------

WHERE V4 BECOMES USEFUL FIRST

五类场景，先落地

01

Code agent
仓库级修复

02

Long doc
报告/合同/论文

03

Knowledge
企业知识库

04

Chinese office
中文办公

05

Private infra
私有化底座

06

Math/STEM
科研推理

07

Customer ops
客服工单

08

Compliance
合规审查

09

Data analysis
数据助理

10

RAG workflow
检索增强

WHAT TO MONITOR AFTER THIS DECK

接下来只看六个信号

01

V4 稳定化

Preview → stable / v4.1

02

API 退役

旧模型名迁移完成度

03

Agent 实战

Claude Code / OpenCode 成功率

04

国产硬件

Ascend 推理成本与稳定性

05

融资落地

股东结构与开放策略

06

监管升级

海外公共部门与企业限制

Enough
good.
Cheap
enough.
*Open
enough.*

DeepSeek 不需要每一项第一。它只需要在足够多的真实任务上，把成本和开放性推到无法忽视。

PUBLIC-SOURCE SYNTHESIS

2026.05

1

01 别再把 R2 当主线

截至 2026-05-24, 官方最新主线是 V4。

02 长上下文要看系统成本

1M token 只有配合缓存、压缩、检索和校验才有产品价值。

03 观察真实生产，不只看 benchmark

V4 的决定性证据，将来自 agent workflow、国产硬件和企业部署。